1. Resumen ejecutivo

En México, la información que necesitan los estudiantes para elegir una carrera está dispersa en portales institucionales, PDFs, bases de datos internas y documentos no estructurados. Esta fragmentación provoca una experiencia de búsqueda confusa, dificulta la comparación de opciones y aumenta la incertidumbre al momento de tomar una decisión académica. **Orienta.ai** se propone resolver este problema mediante un agente inteligente capaz de sintetizar datos provenientes de múltiples fuentes y responder preguntas en lenguaje natural.

Nuestro sistema reúne información sobre carreras universitarias, requisitos de ingreso, costos, becas, estadísticas laborales y oferta educativa. El corazón de la solución es un orquestador implementado en **Oracle Gen AI** que coordina varios módulos especializados: un agente de conversación que construye el perfil del usuario y recomienda carreras, un módulo de recuperación basado en **Retrieval Augmented Generation (RAG)**, un modelo generativo para elaborar respuestas, un módulo de universidades que consulta la oferta académica y un servicio de **Document Understanding** para extraer calificaciones de documentos. Gracias a esta arquitectura, Orienta.ai puede ofrecer orientación personalizada, clara y contextualizada, reduciendo la deserción y facilitando una mejor elección de carrera.

2 Objetivo del proyecto

Diseñar e implementar un sistema de orientación vocacional capaz de centralizar información dispersa sobre carreras universitarias y programas académicos, de modo que los estudiantes de preparatoria puedan realizar preguntas en lenguaje natural y obtener recomendaciones personalizadas. El sistema debe integrar un motor de recomendación híbrido y un chatbot basado en texto, desplegado sobre la infraestructura de Oracle Cloud. De manera general, el proyecto busca: (a) facilitar la búsqueda y comparación de opciones educativas; (b) reducir la incertidumbre en la elección de carrera; y (c) democratizar el acceso a orientación vocacional de calidad.

2.1 Objetivos específicos

1. **Ingesta y limpieza de datos.** Recopilar y depurar las bases de *carreras* y *universidades* para obtener un catálogo unificado de *151 carreras* con sus respectivos perfiles de aptitudes, códigos RIASEC, asignaturas típicas, descripciones profesionales y tendencias de demanda laboral, así como *185 universidades* con su oferta académica, requisitos de ingreso, costos y becas.

2. **Centralización de la información en OCI.** Almacenar los datos previamente depurados en una base de datos de PostgreSQL, asegurando una estructura relacional que facilite consultas semánticas, filtros por estado/tipo de institución y cálculo de similitudes.

3. **Desarrollo del motor de recomendación híbrido.** Construir un motor que combine filtrado basado en contenido (embeddings de descripción de carreras), filtrado colaborativo basado en perfiles de estudiantes simulados e información de mercado laboral. Utilizar técnicas de recuperación de documentos y RAG para enriquecer las descripciones con datos estructurados y ofrecer explicaciones comprensibles.

4. **Implementación de un chatbot conversacional en Oracle Gen AI.** Diseñar intents y diálogos en Gen AI que permitan al usuario expresar intereses, subir su Kardex e interactuar con el motor de recomendación. Integrar módulos para la extracción de texto (OCR) y para la consulta de universidades.

5. **Desarrollo del módulo de universidades y becas.** Crear un microservicio que reciba el nombre de una carrera y devuelva universidades disponibles, costos y reglas de becas, clasificando opciones por tipo de institución y ubicación.

6. **Evaluación y experimentación.** Evaluar el sistema de recomendación mediante 7 pruebas internas y 7 pruebas con usuarios reales, midiendo su desempeño con score global (0–1) y Accuracy ~1. Con base en estos resultados, realizar los ajustes necesarios en las reglas de recomendación para mejorar la precisión y coherencia del sistema.

3. Alcances

El alcance de Orienta.ai comprende la integración de información académica y laboral en un único sistema consultable mediante lenguaje natural. El agente ofrecerá las siguientes funcionalidades:

- **Recomendación de carreras.** Mediante un cuestionario conversacional, el sistema elaborará un perfil del estudiante y sugerirá las tres carreras que mejor se ajusten a sus intereses, aptitudes y desempeño académico.
- **Comparación de universidades.** Para cada carrera recomendada, el usuario podrá consultar universidades públicas y privadas en diferentes estados, con sus costos aproximados y programas de becas disponibles (en caso de que sean universidades privadas).
- **Estadísticas laborales.** El agente proporcionará información sobre demanda laboral, ingresos promedio y tendencia de crecimiento para cada carrera, apoyándose en datos de organismos nacionales y bases estadísticas[3].
- **Extracción de calificaciones.** A partir de documentos o fotografías del kardex de nivel preparatorio (o si es cambio de carrera, el acumulado hasta el cambio en nivel

universitario), el sistema podrá extraer las materias con mejor promedio y calcular el promedio general, de modo que el agente de universidades evalúe si el estudiante es candidato a becas de rendimiento y en algunos casos, extraer información acerca de las materias fuertes y débiles del usuario.[4].

- Interfaz web intuitiva. Se proporcionará una página web desarrollada con Oracle APEX y JavaScript, donde los usuarios podrán interactuar con el chatbot y visualizar la información recomendada.
- El sistema no realiza evaluaciones psicológicas ni pruebas vocacionales validadas. Sus recomendaciones son el resultado de un algoritmo estadístico que calcula la afinidad entre el perfil del usuario y distintas carreras profesionales.
- No se abordan los aspectos administrativos para postular a becas deportivas o culturales, ya que la recomendación se basará únicamente en el promedio académico.
- Los costos y requisitos se presentan de manera aproximada; la inscripción y trámites se deberán confirmar directamente con cada universidad. El sistema sólo ofrece la idea inicial de lo que puede conllevar el proceso de postulación a dichas universidades.

4. Organización del equipo y roles

Para llevar a cabo el proyecto se formó un equipo multidisciplinario, organizado en células de trabajo con responsabilidades bien definidas:

Equipo	Responsabilidades principales
Ingeniería de datos	Reunir, limpiar y normalizar la información de carreras y universidades; diseñar el esquema de las bases de datos y cargar los datos tanto en Oracle Autonomous Database como en local.
Ciencia de datos	Diseñar el modelo de recomendación híbrido (contenido + colaborativo + RAG).
Desarrollo de agentes	Construir los flujos conversacionales en Oracle Gen AI; implementar el orquestador y los módulos de recuperación, generación y universidades (que se manejaron con APIs de OpenAI).
Integración y backend	Desarrollar las APIs que interconectan los módulos; implementar la lógica de negocio en OCI Functions; asegurar la comunicación con la base de datos y servicios externos.
Interfaz de usuario	Diseñar el prototipo de la web en Figma; implementar la aplicación con Oracle APEX y JavaScript; garantizar la accesibilidad y usabilidad del chatbot.

Pruebas y documentación	Planificar y ejecutar pruebas funcionales y de usuario; recopilar métricas de satisfacción; documentar cada fase del proyecto y elaborar el informe final.

5. Planificación de tareas

La planificación se estructuró en un cronograma tipo Gantt que abarca del **1 de noviembre al 1 de diciembre de 2025**. Las actividades principales se enumeran en la *figura 1* y se desarrollaron de manera incremental para permitir retroalimentación continua y ajuste de prioridades.

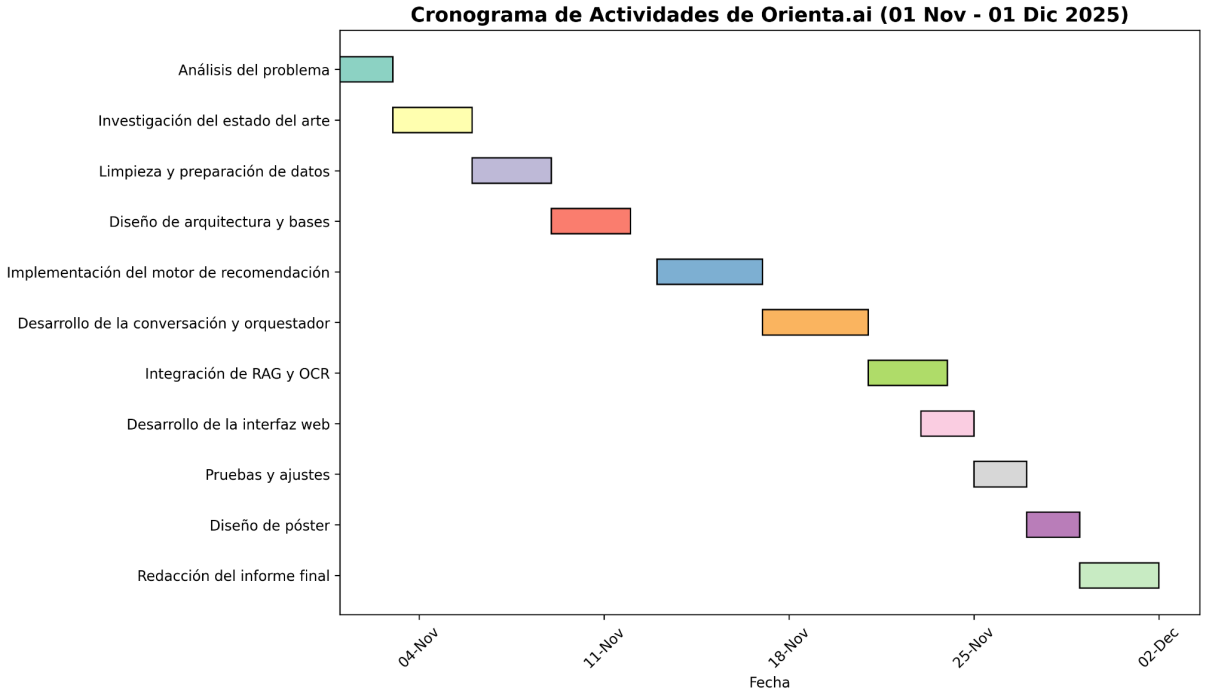

(Figura 1, Cronograma del proyecto Orienta.ai)

La planificación contempla nueve fases principales: (1) definición de objetivos y requisitos; (2) investigación del estado del arte y diseño conceptual; (3) preparación de los datos; (4) construcción del modelo de recomendación; (5) implementación del motor de búsqueda y RAG; (6) implementación del chatbot en ODA; (7) integración con OCR y el módulo de universidades; (8) pruebas y evaluación; y (9) redacción del informe y presentación final. Cada fase se asignó a la célula correspondiente y se realizaron reuniones de sincronización semanales.

Fase / Tarea	Responsable(s)
Definición de objetivos y requisitos	**Andrew Williams**, **Marco Miloslavich**
Investigación del estado del arte y diseño conceptual	**Samuel López**
Preparación de los datos	**Andrew Williams, Alejandro Miloslavich**, **Luis Navarro, Bruno Zamora**, **Andrés Pi**
Construcción del modelo de recomendación	**Luis Navarro, Bruno Zamora**
Implementación del motor de búsqueda y RAG	**Andrés Pi, Andrew Williams**
Implementación del chatbot en ODA	**Samuel López**, **Luis Navarro**
Integración de OCR y módulo de universidades	**Alejandro Miloslavich , Marco Miloslavich**
Pruebas y evaluación	**Bruno Zamora**, **Andrés Pi**
Redacción del informe y presentación final	**Marco Miloslavich**, **Bruno Zamora**, **Samuel López**,

6. Estado del arte

6.1 Recomendadores de carreras y sistemas híbridos

Las primeras aproximaciones de orientación automatizada se basaron en sistemas de filtrado de contenido, que recomiendan carreras a partir de las características del usuario y de los programas académicos; estos sistemas ofrecen coincidencias estrechas, pero sufren problemas de arranque en frío y tienden a generar “cámaras de eco” al limitar la diversidad de opciones consideradas por la persona usuaria [5]. El filtrado colaborativo, por su parte, utiliza patrones de usuarios similares y permite sugerencias menos evidentes, aunque depende de grandes volúmenes de datos históricos y se ve afectado por la escasez de interacciones en etapas tempranas [6]. Los sistemas híbridos combinan ambas técnicas para mejorar la precisión, la diversidad y la estabilidad de las recomendaciones; en los enfoques más recientes se integran modelos de lenguaje (LLM) para interpretar textos no estructurados, como descripciones de carreras y perfiles narrativos de los usuarios [7]. Un estudio de 2025 presentó un recomendador de trayectoria profesional que emplea aprendizaje profundo, aprendizaje por refuerzo y técnicas de

PLN para sugerir opciones personalizadas; el sistema alcanzó una exactitud del 90.06 % y una precisión del 92.07 % al predecir trayectorias en el ámbito STEM [8].

Paralelamente, en la práctica, los "líderes de mercado" en orientación vocacional siguen siendo los tests psicométricos estandarizados disponibles en línea, que suelen incluir entre 60 y 100 reactivos de opción cerrada, con escalas tipo Likert (por ejemplo, de 1 a 5). Aunque estos instrumentos permiten comparar resultados entre grandes poblaciones, presentan limitaciones importantes: restringen la expresión del usuario a respuestas predefinidas, capturan con dificultad matices personales y contextuales, y rara vez se adaptan dinámicamente a lo que la persona va explicando durante el proceso. Frente a ese enfoque rígido de cuestionario lineal, comienzan a explorarse alternativas basadas en agentes conversacionales capaces de formular preguntas abiertas, profundizar en aspectos relevantes y ajustar el diálogo según las respuestas, lo que abre la puerta a perfiles más ricos y personalizados para la recomendación de carreras.

6.2 Recuperación aumentada con generación (RAG) en orientación

La técnica **Retrieval Augmented Generation (RAG)** combina un componente de recuperación de información con un modelo generativo; al consultar documentos relevantes antes de generar una respuesta, se mejora la exactitud factual y se reducen las alucinaciones. Un estudio piloto realizado en 2025 comparó un agente RAG con un modelo de lenguaje base para asesorar a estudiantes de preparatoria: se evaluaron 100 preguntas con 25 estudiantes y se observó que RAG mejoró la claridad, relevancia y empatía de las respuestas, además de reducir la tasa de errores[9]. El artículo destaca la importancia de emplear marcos tradicionales de desarrollo vocacional (RIASEC, Super, SCCT) y de mantener bases de conocimiento curadas para la recuperación[10].

6.3 Ética y principios en sistemas de IA educativa

La adopción de sistemas de inteligencia artificial en educación exige marcos claros de ética y gobernanza que protejan a las personas usuarias. Diversos organismos especializados han propuesto principios como la beneficencia (maximizar beneficios y minimizar daños), la justicia (evitar la discriminación y promover la equidad), el respeto por la autonomía (consentimiento informado y control sobre la propia información), la transparencia y explicabilidad de los procesos automatizados, la responsabilidad de los desarrolladores e instituciones, y la protección de la privacidad y los datos personales [11].

Estos principios orientan el diseño de Orienta.ai: la transparencia en el origen y uso de los datos , la equidad en las recomendaciones (evitar sesgos que favorezcan o excluyan sistemáticamente a ciertos perfiles) y la protección de los datos académicos del estudiante son elementos centrales del proyecto. Además, se busca que las recomendaciones sean explicables indicando por qué se sugieren ciertas carreras y que el estudiante conserve la capacidad de cuestionarlas,

complementarlas o descartarlas, manteniendo así su autonomía en la toma de decisiones sobre su trayectoria educativa.

6.4 Modelos generativos en Oracle Digital Assistant

Oracle Gen AI evolucionó de manejar únicamente IA predictiva, donde se clasifican mensajes según un conjunto de flujos predefinidos, a potenciarse con funcionalidades de IA generativa proporcionadas por Oracle Generative AI Service, a través de componentes como Knowledge Dialogs y LLM Blocks[12].

- **Knowledge Dialogs:** permite cargar documentos en una base de datos vectorial interna y realizar búsquedas avanzadas para responder preguntas sin necesitar integraciones externas. Su ventaja es la simplicidad y la seguridad, pues la información se mantiene en el mismo servidor del chatbot; sin embargo, en su primera versión estaba limitada y no permitía filtrar contenido por usuario ni refinar los prompts[13].

- **LLM Blocks**: ofrecen conectividad a servicios externos como Azure OpenAI y Cohere mediante llamadas REST, facilitando la personalización del prompt, la transmisión de mensajes y la formateo de la salida. Esta función amplía las posibilidades del chatbot al permitir conversaciones dinámicas y contextuales[14].

Estas capacidades permiten a Orienta.ai combinar la recuperación de datos con un modelo generativo para producir respuestas fluidas y personalizadas.

6.5 Extracción de texto y clasificación de documentos

El servicio **OCI Document Understanding** proporciona modelos pre-entrenados para extracción de texto, extracción de pares clave-valor, extracción de tablas y clasificación de documentos. Estos modelos pueden usarse tal cual o entrenarse con datos etiquetados para adaptarse a casos particulares. La integración con la API de Python permite cargar documentos desde **Object Storage**, ejecutar trabajos de procesamiento y recuperar los resultados en formato estructurado[15]. Este servicio resulta ideal para extraer calificaciones de certificados escolares y complementar el perfil del estudiante con su rendimiento académico.

6.6 Estadísticas laborales y top 10 de carreras

El Observatorio Laboral de México publica datos sobre la demanda y los salarios de las profesiones. Según su informe de carreras con mayor ingreso (actualizado al primer trimestre de 2017), las diez carreras mejor pagadas son: **Química** ($25 486 MXN mensuales), **Física** ($19 224 MXN), **Minería y extracción** ($18 008 MXN), **Finanzas, banca y seguros** ($16 632 MXN), **Farmacia** ($16 109 MXN), **Estadística** ($15 835 MXN), **Servicios de transporte**

($15 492 MXN), **Medicina** ($14 610 MXN), **Ingeniería industrial, mecánica, electrónica y tecnologías afines** ($14 426 MXN) y **Construcción e ingeniería civil** ($14 168 MXN)[16]. Estos valores proporcionan un contexto económico para orientar al estudiante y se utilizan en el módulo de estadísticas de Orienta.ai.

7. Marco teórico

7.1 Modelo RIASEC de Holland

John Holland propuso que las personas y los entornos laborales pueden clasificarse en seis tipos básicos: **Realista**, **Investigador**, **Artístico**, **Social**, **Emprendedor** y **Convencional**[17]. Cada tipo describe intereses y competencias particulares: por ejemplo, el perfil *Realista* valora trabajar con las manos y emplear herramientas; el perfil *Investigador* disfruta descubrir, investigar y resolver problemas; el perfil *Artístico* se expresa a través del arte y la creación; el perfil *Social* se enfoca en ayudar, enseñar y servir a otros; el perfil *Emprendedor* se orienta a liderar, persuadir y gestionar negocios; y el perfil *Convencional* prefiere actividades ordenadas y de organización de datos.

El sistema RIASEC ha sido ampliamente utilizado en orientación vocacional y explica que las personas tienden a ser más exitosas y satisfechas cuando trabajan en entornos congruentes con su tipo dominante[18]. Orienta.ai utiliza este modelo para etiquetar las carreras de la base de datos y relacionar los intereses del estudiante con las opciones disponibles.

7.2 Teoría del ciclo vital y los roles vitales (Super)

Donald Super planteó que el desarrollo de la carrera es un proceso que dura toda la vida y que las personas cumplen distintos roles según la etapa: crecimiento, exploración, establecimiento, mantenimiento y retirada[19]. La **vida útil** se refiere a la evolución de la carrera a lo largo del tiempo, mientras que la **vida espacial** considera las múltiples funciones que una persona desempeña (hijo/a, estudiante, trabajador/a, cónyuge, etc.)[20]. La teoría de Super resalta que la elección de carrera se basa en el desarrollo del autoconcepto y en la interacción con el entorno, y que la satisfacción se logra cuando las actividades laborales permiten expresar ese autoconcepto[21]. Esta perspectiva fundamenta la importancia de recopilar información detallada sobre el perfil del estudiante antes de recomendar una trayectoria académica.

7.3 Teoría cognitivo-social de la carrera (SCCT)

La **Social Cognitive Career Theory** explica que las decisiones vocacionales surgen de la interacción entre factores personales (autoeficacia, expectativas de resultados), factores

ambientales y comportamiento[22]. La autoeficacia se refiere a las creencias sobre la propia capacidad para realizar una actividad; las expectativas de resultados, a las consecuencias anticipadas de dicha actividad; y las metas personales, al compromiso con ciertos objetivos[23]. SCCT destaca que las personas desarrollan intereses y eligen carreras en función de experiencias previas de éxito o fracaso, de modelos de referencia y del apoyo social disponible. En Orienta.ai, este marco inspira la necesidad de contemplar aspectos ambientales y de autoconfianza al construir el perfil del usuario y al generar recomendaciones.

7.4 Modelado estructurado de carreras y del perfil vocacional en Orienta.AI

Para aplicar las teorías presentadas, Orienta.ai utiliza un catálogo estructurado de carreras donde cada programa se describe mediante atributos que reflejan los principales modelos de elección vocacional.

El modelo RIASEC de Holland se integra mediante etiquetas de intereses (como RI, IAS o SEC) y descripciones del tipo de actividades propias de la profesión. Esto permite comparar los intereses del estudiante recopilados por el agente mediante preguntas sobre actividades, materias y proyectos que disfruta con el entorno típico de cada carrera, buscando congruencia persona–entorno.

La teoría de Super se retoma a través de columnas que describen aptitudes y actitudes clave, además de información relacionada con experiencias previas y formas de trabajar. El agente obtiene estos datos preguntando por tareas donde el estudiante ha tenido mejor desempeño, lo cual ayuda a perfilar su autoconcepto.

Por su parte, la SCCT (Social Cognitive Career Theory)se refleja en atributos vinculados con valores laborales, expectativas y contexto, como estabilidad, presión, tipo de impacto, rangos de ingreso y nivel de competitividad. El agente recoge información sobre prioridades personales (propósito, ingreso, flexibilidad), tolerancia al riesgo, apoyos y posibles barreras, de forma coherente con los factores que la SCCT considera determinantes en la elección vocacional.

Este diseño permite comparar el perfil del estudiante con las carreras en múltiples dimensiones, no solo intereses. La base de datos funciona como una representación sistemática de los entornos vocacionales descritos por Holland, Super y la SCCT, y sirve como fundamento para los métodos de similitud y recomendación del sistema, explicados en la metodología.

8. Limpieza y preparación de los datos

Todas las bases de datos utilizadas en Orienta.ai fueron elaboradas de manera manual por el equipo del proyecto, a partir de la revisión de portales educativos, sitios oficiales de universidades, páginas especializadas en estadísticas de carreras y otras fuentes públicas relacionadas con oferta académica y mercado laboral. Posteriormente, se aplicó un proceso de depuración y estandarización para garantizar la coherencia de la información antes de integrarla al sistema de recomendación.

8.1 Descripción de las bases de datos

Base Carreras. El archivo base_carreras contiene 176 registros de carreras universitarias. Cada registro incluye atributos como: nombre de la carrera, área general de conocimiento, industria asociada, código RIASEC, aptitudes y actitudes clave, tipo de trabajo dominante, nivel de contacto con personas, nivel de trabajo en equipo, entorno de trabajo típico, descripción de la salida laboral y tendencias de demanda, entre otros campos.

Las carreras se agrupan en 7 áreas generales y 10 industrias diferentes (números que pueden corresponder a macro-categorías como salud, ingeniería, ciencias sociales, artes, negocios, medio ambiente, etc.). Esta estructura permite mapear de manera explícita la relación entre intereses, habilidades, valores y contextos ocupacionales, lo que resulta fundamental para comparar el perfil del estudiante con los distintos programas académicos.

Base Universidades. La base de datos de universidades compila 185 universidades distribuidas en los 32 estados de México. Para cada institución se registran los programas académicos que ofrece (oferta_academica), los requisitos de ingreso, si es pública o privada, el costo de colegiatura en caso de ser privada, la existencia de becas, así como el estado y la ciudad donde se encuentra ubicada. Esta base de datos se utiliza principalmente para filtrar las universidades que ofrecen las carreras recomendadas por el sistema y para estimar los costos y apoyos económicos disponibles para el estudiante.

8.2 Análisis exploratorio de los datos

Antes de construir el motor de recomendación, se realizó un análisis exploratorio de la base de datos con el fin de comprender su estructura y la distribución de la oferta académica representada. El conjunto contiene 176 carreras, organizadas en 7 áreas generales de conocimiento.

Las áreas con mayor número de programas son Ingeniería y Tecnología (69 carreras), seguida por Ciencias Sociales y Humanidades (30) y Negocios, Economía y Administración (22). En contraste, existen áreas con menor representación, como Ciencias Agropecuarias y Medio Ambiente (6 carreras). Esta distribución refleja una tendencia nacional ampliamente documentada: la mayor parte de la oferta educativa se concentra en disciplinas científicas,

tecnológicas y sociales, mientras que los campos agropecuarios y algunos sectores artísticos presentan una disponibilidad más limitada.

Las industrias asociadas a las carreras también presentan concentración. Las combinaciones más frecuentes son Tecnología de la información y servicios profesionales, Educación y servicios profesionales, Energía y servicios públicos, y Telecomunicaciones. Esta diversidad industrial permite conectar las carreras con sectores productivos específicos y orientar al usuario hacia campos con demanda laboral.

En la base de universidades, se registran 185 instituciones repartidas en 32 estados. Los estados con mayor número de universidades son Puebla, Jalisco, Ciudad de México (CDMX), Nuevo León y Durango, cada uno con 10 instituciones. Les siguen Aguascalientes, Sinaloa, Querétaro, Quintana Roo y San Luis Potosí, con 5 universidades cada uno. Esta información es útil para determinar la cobertura territorial y dirigir al módulo de universidades a regiones de alta y baja oferta académica.

Área general	**Número de carreras**
Ingeniería y Tecnología	69
Ciencias Sociales y Humanidades	30
Negocios, Economía y Administración	22
Ciencias de la salud	18
Ciencias Naturales y Exactas	16
Artes, Arquitectura y Diseño	15
Ciencias Agropecuarias y Medio Ambiente	6

(Tabla 1, Análisis de datos)

Estado	**Número de universidades**
Puebla	10
Jalisco	10
Ciudad de México (CDMX)	10
Nuevo León	10
Durango	10

(Tabla 2, Análisis de datos)

8.3 Proceso de limpieza

1. **Eliminación de duplicados.**
   Se identificaron y eliminaron registros repetidos tanto en la base de carreras como en la base de universidades. En el caso de las carreras, se consideró como clave el nombre de la licenciatura junto con su área/industria; para las universidades, se tomó en cuenta el nombre de la institución y su estado/ciudad, con el fin de evitar entradas duplicadas que pudieran sesgar las recomendaciones.
2. **Homologación de nombres.**
   Los nombres de las carreras y de las universidades se normalizaron (uso consistente de mayúsculas/minúsculas, eliminación de acentos y caracteres especiales cuando era pertinente) para reducir discrepancias durante los procesos de búsqueda y emparejamiento. Asimismo, se unificaron variantes de un mismo término (por ejemplo, "TECNOLOGÍA" vs. "TECNOLOGÍAS") y se estandarizaron las etiquetas de áreas generales e industrias según un catálogo cerrado.
3. **Compleción de campos faltantes.**
   Para las carreras que presentaban campos vacíos (por ejemplo, nivel de contacto con personas, entorno de trabajo o descripción de la salida laboral), se consultaron nuevamente fuentes oficiales y se completaron los datos de manera manual. En la base de universidades, se revisaron los costos de colegiatura y, cuando el valor exacto no estaba disponible, se emplearon rangos aproximados coherentes con el tipo de institución y el contexto regional, dejando constancia de dichas estimaciones.
4. **Etiquetado RIASEC.**
   Se asignaron códigos RIASEC a todas las carreras con base en la descripción de sus competencias, actividades típicas y entornos laborales. Este etiquetado permite utilizar el modelo RIASEC tanto para el filtrado basado en contenido como para la comparación con los intereses declarados por el estudiante dentro del agente conversacional.

8.4 Preparación y transformación

Para aplicar técnicas de recomendación y de recuperación aumentada por generación (RAG), los campos textuales (que ocupaban una mayor semántica) de las bases (por ejemplo, aptitudes, actitudes, entorno de trabajo, salida laboral y tendencias de demanda) se sometieron a un preprocesamiento ligero y se transformaron en vectores densos mediante modelos de lenguaje pre-entrenados (*embeddings*). A partir de estos, se construyó un perfil vectorial para cada carrera, combinando sus campos más informativos, y un perfil vectorial del usuario a partir de las respuestas recogidas por el agente conversacional en las mismas dimensiones (intereses, habilidades, valores y entorno deseado).

Todos los vectores de carrera se almacenaron en una base de datos vectorial, lo que permite comparar el perfil del estudiante con las distintas opciones académicas mediante métricas de similitud y recuperar, vía RAG, los textos asociados a las carreras más cercanas para generar explicaciones personalizadas de las recomendaciones.

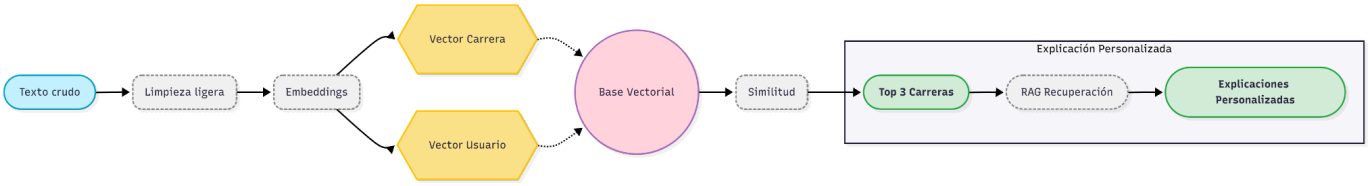

(Figura 2, Preparación y transformación)

9. Arquitectura del sistema

La figura X ilustra la arquitectura general de Orienta.ai. El usuario interactúa mediante una interfaz web y envía sus preguntas al **orquestador**, implementado en Oracle Gen AI. Este orquestador actúa como punto central de entrada y salida: recibe los mensajes del estudiante, decide qué módulo debe participar en cada momento y combina las respuestas parciales en una respuesta final coherente.

En la capa lógica, el orquestador coordina varios servicios especializados:

1. **Agente de conversación y recomendación.**
   Es el responsable de conducir la entrevista vocacional en lenguaje natural. Formula preguntas, recoge intereses, calificaciones, experiencias y preferencias del estudiante y construye un perfil estructurado. A partir de este perfil, invoca al **motor de recomendación**, desplegado como servicio independiente, para obtener un *top 3* de carreras. Este motor utiliza la base de datos de carreras, los vectores previamente calculados y reglas adicionales de compatibilidad para calcular las recomendaciones.
2. **Módulo de recuperación semántica (RAG).**
   Expone una API que realiza búsquedas semánticas sobre la base de datos de carreras y universidades. Para ello se apoya en una **base de vectores** almacenada en TimescaleDB (mediante extensiones de vectorización), donde cada carrera y universidad tiene un perfil vectorial. El módulo recibe como entrada el perfil del usuario o una pregunta específica y devuelve los pasajes más relevantes, que luego son usados por el modelo generativo para explicar por qué se sugiere cada carrera u ofrecer información adicional.
3. **Modelo generativo (LLM).**
   Recibe tanto el historial de conversación como los fragmentos recuperados por el módulo RAG y genera respuestas en lenguaje natural: explicaciones de las recomendaciones, aclaración de dudas sobre las carreras o sugerencias de próximos pasos. Este modelo también da vida a otros agentes especializados (por ejemplo, el

agente que describe universidades o el que explica qué significa cada carrera recomendada), todos coordinados por el orquestador.

4. **Agente de universidades.**
   Una vez obtenido el *top 3* de carreras, el orquestador puede invocar un agente específico que consulta la **base de universidades** para listar instituciones que ofrecen esas carreras, filtrando por estado, tipo de institución (pública/privada), rangos de colegiatura y opciones de becas. Este agente formatea la información en un resumen entendible para el estudiante.
5. **Agente OCR / Document Understanding.**
   Para quienes suben su kardex o historial académico, el orquestador llama a un servicio de OCR y *Document Understanding* que extrae calificaciones y materias de documentos PDF o imágenes. El resultado se convierte en un JSON estructurado que se usa para evaluar el rendimiento del estudiante, identificar materias fuertes y débiles y, en una etapa posterior, estimar si cumple criterios básicos para ciertos tipos de beca.

En la capa de datos, todas las consultas estructuradas se realizan sobre una **base centralizada** de carreras y universidades, implementada en TimescaleDB, donde también se almacenan los vectores utilizados para la búsqueda semántica. Estas bases, junto con los servicios de recomendación y RAG, se despliegan en **contenedores Docker**, lo que facilita su administración, escalamiento y despliegue en la nube.

En conjunto, esta arquitectura permite que Orienta.ai combine el diálogo natural con el estudiante, la búsqueda semántica en grandes volúmenes de texto y el uso de datos estructurados sobre carreras y universidades, para ofrecer recomendaciones personalizadas y explicables sobre posibles trayectorias académicas.

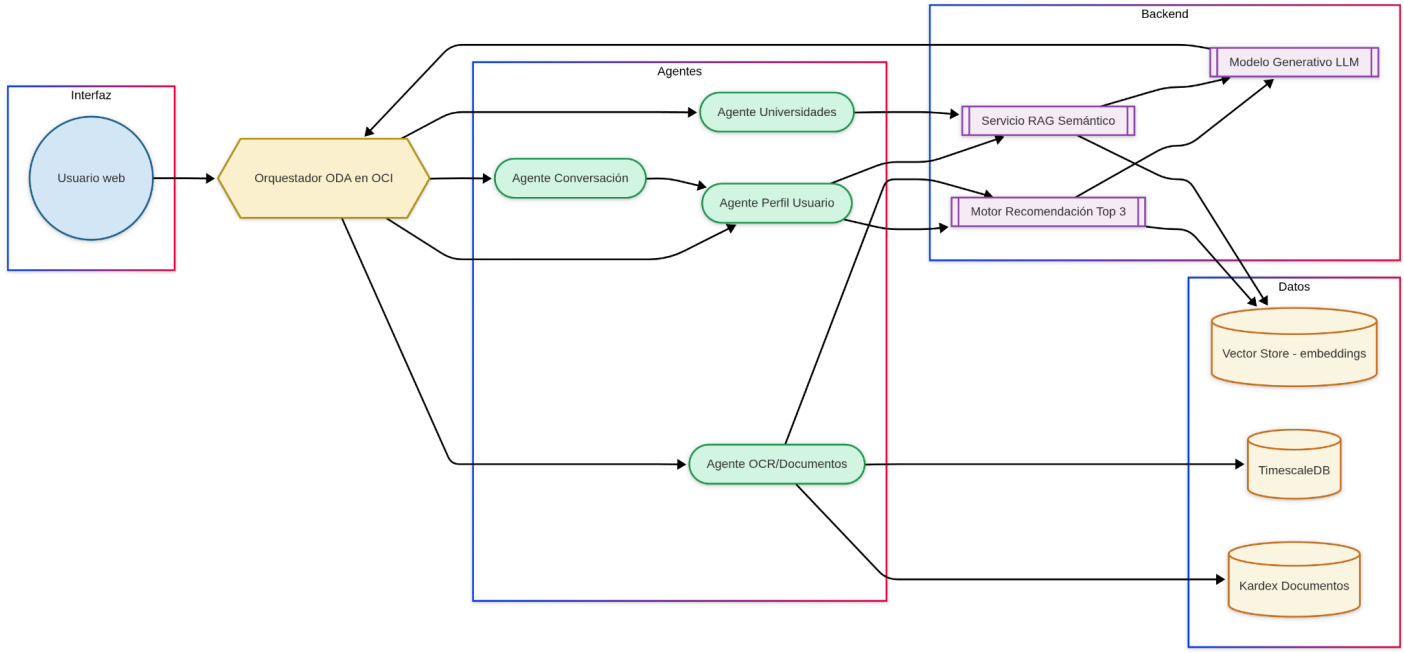

(Figura 3, Arquitectura y flujo de Orienta.ai)

10. Diseño del modelo de recomendación (motor de recomendación)

El motor de recomendación de Orienta.ai estima, para cada carrera del catálogo, un grado de ajuste vocacional respecto al perfil del estudiante y, a partir de ello, propone un top 3 de carreras.

El diseño es híbrido y combina:

1. **Modelo basado en contenido**
   Compara directamente el perfil del estudiante con las características de cada carrera (intereses RIASEC, aptitudes, actitudes, valores, materias, entorno de trabajo, área general, industria, etc.).

2. **Módulo semántico tipo RAG + modelo de lenguaje interno**
   El sistema cuenta internamente con un módulo de lenguaje natural que utiliza:

   - Representaciones vectoriales (embeddings) del catálogo de carreras, y los textos clave del perfil del estudiante,

Para revisar la coherencia de las recomendaciones, desempatar opciones muy cercanas en score y generar explicaciones en lenguaje natural. Este módulo funciona de manera interna dentro del motor (no se presenta como un "segundo agente" hacia el usuario).

De forma simplificada, el flujo es:

1. Se realiza una **entrevista conversacional** con el estudiante y se obtiene un perfil crudo en lenguaje natural.
2. Internamente se normalizan y estructuran esas respuestas, produciendo un **perfil_usuario_final** con campos estandarizados y textos limpios.
3. El motor compara ese perfil con todas las carreras usando:
    - comparaciones por **catálogos** (áreas, industria, materias, tipo de trabajo, entornos, niveles), y
      comparaciones **semánticas** mediante embeddings y distancia coseno.
4. Se calculan **sub-scores** por dimensión, se combinan con pesos predefinidos y se obtiene un **score global** por carrera.
5. Se ordenan las carreras por score y se selecciona el **top 3**; el módulo semántico interno ayuda a elaborar las explicaciones finales.

10.1 Representación vectorial de las carreras

Cada carrera ***j*** se representa mediante un conjunto de atributos numéricos y categóricos que se convierten en **sub-scores normalizados entre 0 y 1**.

10.1.1 Campos del catálogo de carreras

Las columnas principales utilizadas por el motor son:

Tipo de agrupación de dimensiones	**Dimensiones de la agrupación (columnas base de datos)**
Identificación y contexto general	• id_carrera • nombre_carrera • area_general • industria
Intereses y vocación	• codigo_riasec • descripcion_riasec • que_se_hace_carrera • que_se_hace_mundo_profesional • perfil_laboral_y_valores • salida_laboral

Aptitudes, actitudes y forma de ayudar	• aptitudes_clave • actitudes_clave • como_ayuda *(En estos campos, las opciones se almacenan típicamente como listas separadas por ';'.)*
Dimensión académica	materias_fuertes_prepa
Entorno de trabajo y niveles ordinales	• tipo_trabajo_dominante • entorno_trabajo_tipico • nivel_contacto_personas • nivel_trabajo_equipo • ayuda_directamente_personas

(Tabla 3, Campos del catálogo de carreras)

10.1.2 Campos comparados por catálogos cerrados

Varias dimensiones se comparan usando **catálogos cerrados** que garantizan consistencia entre el perfil del estudiante y la base de carreras:

1. **Área general / áreas preferidas**
   Para el usuario se usa el catálogo:

- "Ciencias de la salud"
- "Ingeniería y tecnología"
- "Ciencias naturales y exactas"
- "Ciencias sociales y humanidades"
- "Negocios y administración"
- "Artes, diseño y creatividad"
- "Agro, medio ambiente y recursos naturales"

El campo del perfil **areas_preferidas** es una lista ordenada basada en estos textos exactos. Esta lista se compara con **area_general** de la carrera para obtener el score de área (ver 10.3.2).

2. **Industria preferida**

Catálogo:

- "Salud y bienestar"
- "Educación y formación"
- "Ciencia, investigación y desarrollo tecnológico"
- "Negocios, finanzas y consultoría"
- "Gobierno, políticas públicas y servicios públicos"

- “Sociales, ONG y desarrollo comunitario”
- “Ingeniería, manufactura y energía”
- “Tecnología de la información y software”
- “Medio ambiente, agro y recursos naturales”
- “Arte, medios, cultura y entretenimiento”

El perfil usa **industria_preferida** (un solo valor de la lista), que se compara con **industria** de la carrera.

3. **Materias (like / dislike)**

Se definen etiquetas genéricas para agrupar materias de bachillerato:

- “
- Matemáticas”
- “Matemáticas (razonamiento lógico y problemas)”
- “Física”
- “Química”
- “Biología”
- “Ciencias Naturales”
- “Tecnología / Computación / Programación”
- “Historia”
- “Ciencias Sociales / Filosofía / Sociología”
- “Economía / Administración”
- “Lengua y Literatura / Español”
- “Inglés”
- “Arte / Artes visuales / Música / Teatro”
- “Dibujo técnico / Dibujo artístico”
- “Metodología / Taller de investigación”
- “Proyecto integrador / Emprendimiento”

Las materias que menciona el usuario en lenguaje natural se mapean a estas etiquetas para poblar **materias_like** y **materias_dislike**. Estas listas se comparan con **materias_fuertes_prepa** de cada carrera.

4. **Tipo de trabajo dominante del usuario**

El usuario elige un solo valor:

- “Analítico / cuantitativo”
- “Práctico / técnico”
- “Creativo / diseño”
- “Social / servicio directo a personas”
- “Gestión / liderazgo”
- “Investigación / académico”
- “Emprendimiento / negocios / creación de proyectos”

Este campo (**tipo_trabajo_dominante_usuario**) se compara con **tipo_trabajo_dominante** de la carrera.

5. **Entornos preferidos**

El usuario puede seleccionar 1–2 entornos de:

- "Oficina / trabajo administrativo"
- "Laboratorio / centro de investigación"
- "Campo / trabajo al aire libre"
- "Hospital / clínica / servicio de salud"
- "Planta industrial / taller / instalaciones técnicas"
- "Aula / institución educativa"
- "Entorno urbano / comunitario / trabajo de campo social"
- "Espacios creativos / estudio / taller artístico"
- "Entorno digital / trabajo remoto / híbrido"
- "Servicios / atención al cliente / turismo"

Aqui **entornos_preferidos**, que se compara con **entorno_trabajo_tipico** de la carrera (lista separada por ';').

6. **Niveles ordinales de contacto, equipo y ayuda directa**

❖ **nivel_contacto_personas_usuario**:
  ➢ 1 = poco contacto
  ➢ 2 = medio
  ➢ 3 = mucho

❖ **nivel_trabajo_equipo_usuario**:
  ➢ 1 = prefiere trabajar más individual
  ➢ 2 = mixto
  ➢ 3 = mucho trabajo en equipo

❖ **quiere_ayuda_directa**:
  ➢ 1 = poco (impacto más indirecto)
  ➢ 2 = medio
  ➢ 3 = mucho (ayuda cara a cara)

Estos niveles se comparan con los niveles típicos de la carrera (**nivel_contacto_personas**, **nivel_trabajo_equipo**, **ayuda_directamente_personas**), que internamente se codifican como "bajo", "medio", "alto" y luego se convierten a valores 1, 2, 3.

7. **Código RIASEC del usuario**

codigo_riasec_usuario es una combinación de 2 o 3 letras entre:

- R: Realista
- I: Investigador
- A: Artístico
- S: Social
- E: Emprendedor
- C: Convencional

Se compara con **codigo_riasec** de la carrera.

10.1.3 Embeddings para textos largos y distancia coseno

Los campos textuales extensos (por ejemplo, **perfil_laboral_y_valores**, **que_se_hace_carrera**, **que_se_hace_mundo_profesional**, **salida_laboral**, así como los textos equivalentes del usuario) se representan mediante embeddings de texto de dimensión fija d=3072

En concreto, se utilizó el modelo text-embedding-3-large de OpenAI, un modelo preentrenado que se usa únicamente en modo inferencia (no se realizó entrenamiento adicional ni ajuste fino por parte del equipo).

Sea $f(\cdot)$ el modelo de embeddings. Por ejemplo, para una carrera j:

v **valores** = f(perfil_laboral_y_valores j)

v **mundo** = f(que_se_hace_mundo_profesional j)

Y para el usuario:

u **valores** = f(texto_valores_laborales)
u **vision** = f (texto_vision_trabajo) u vision

La similitud entre vectores se calcula mediante distancia coseno. Primero se obtiene la similitud coseno:

$$[\mathrm{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|},]$$

y luego la distancia coseno:

$$[d_{\cos}(\mathbf{u}, \mathbf{v}) = 1 - \mathrm{sim}_{\cos}(\mathbf{u}, \mathbf{v}),]$$

10.1.4 “Chunks” de texto y boosts simbólicos

Para descripciones largas de la carrera (**que_se_hace_carrera**, **que_se_hace_mundo_profesional**, **salida_laboral**), el motor también realiza una detección de **chunks**: divide el texto de la carrera en frases separadas por ‘;’ y revisa si alguna de esas frases aparece (normalizada) dentro del texto del usuario.

Si al menos un chunk está contenido en el texto del estudiante, se le asigna un score de chunk = 1.0 para esa dimensión, que funciona como un boost simbólico, combinado con el score obtenido por embeddings completo del texto.

10.2 Construcción del perfil del estudiante

A partir de la conversación, el sistema genera un perfil estructurado (**perfil_usuario**) que “habla el mismo idioma” que la base de carreras.

10.2.1 Del perfil crudo al perfil estructurado

Durante la entrevista el estudiante responde con lenguaje natural a preguntas sobre:

- actividades que disfruta,
- materias fuertes y débiles,
- experiencias previas,
- valores laborales,
- visión de futuro,
- preferencias de entorno y tipo de trabajo, etc.

Con esto se construye un perfil crudo. Internamente, el sistema:

1. Generaliza y normaliza respuestas hacia los catálogos definidos:

- asigna **areas_preferidas** con textos exactos del catálogo de áreas,
- elige una **industria_preferida** del catálogo de industrias,
- mapea materias concretas a **materias_like** y **materias_dislike** usando las etiquetas genéricas,
- elige **tipo_trabajo_dominante_usuario**,
- elige 1–2 **entornos_preferidos**,
- asigna niveles **nivel_contacto_personas_usuario**, **nivel_trabajo_equipo_usuario**, **quiere_ayuda_directa**,
- determina **codigo_riasec_usuario** con 2–3 letras RIASEC.

2. Conserva y limpia textos para comparación semántica:

- texto_aptitudes,
- texto_actitudes,
- texto_como_quiere_ayudar,
- texto_vision_trabajo,
- texto_valores_laborales,
- texto_intereses,
- resumen_global_usuario.

Este perfil estructurado se usa tanto para las comparaciones por catálogo como para las comparaciones por embeddings.

10.2.2 Vectores del usuario

Del perfil_usuario_final se derivan:

- Embeddings de textos para comparación coseno:
  - ➔ u **valores** = f (texto_valores_laborales)
  - ➔ u **vision** = f (texto_vision_trabajo)

- Variables categóricas normalizadas:
  - areas_preferidas, industria_preferida,
  - materias_like, materias_dislike,
  - tipo_trabajo_dominante_usuario,
  - entornos_preferidos,
  - codigo_riasec_usuario.

- Variables ordinales:
  - nivel_contacto_personas_usuario,
  - nivel_trabajo_equipo_usuario,
  - quiere_ayuda_directa.

Con ello, tanto el usuario como las carreras quedan representados en un espacio común de características que permite calcular sub-scores $s_{jk} \in [0,1]$ para cada dimensión k.

10.3 Cálculo del score y generación del top 3

10.3.1 Dimensiones y pesos

El motor define un conjunto de dimensiones k, cada una con un peso w_k y un sub-score para la carrera j.

- **BLOQUE PRINCIPAL: Intereses y vocación (40%)**
    - que_se_hace_mundo_profesional → peso 0.15
    - riasec → peso 0.12
    - perfil_laboral_y_valores → peso 0.12
- **BLOQUE APTITUDES Y HABILIDADES (25%)**
    - aptitudes_clave → peso 0.12
    - actitudes_clave → peso 0.08
    - como_ayuda → peso 0.05
- **BLOQUE ACADÉMICO (20%)**
    - materias_fuertes_prepa → peso 0.10
    - que_se_hace_carrera → peso 0.06
    - materias_carrera → peso 0.04
- **BLOQUE ENTORNO LABORAL (10%)**
    - tipo_trabajo_dominante → peso 0.05
    - entorno_trabajo_tipico → peso 0.03
    - salida_laboral → peso 0.02
- **BLOQUE CONTEXTO (5%)**
    - area_general → peso 0.03
    - contacto_personas → peso 0.01
    - nivel_trabajo_equipo → peso 0.005
    - ayuda_directamente_personas → peso 0.005
    - industria → peso 0.01

La suma de todos los pesos es 1.00.

10.3.2 Funciones de score por tipo de variable

1. **Variables basadas en embeddings (texto largo)**
   Ejemplos:**perfil_laboral_y_valores**,**que_se_hace_carrera**,**que_se_hace_mundo_profesional**, **salida_laboral**, parte de RIASEC.

- Se calcula la distancia coseno d_{cos} entre el embedding del usuario y el de la carrera.
- Se aplica la transformación:=

$$[s = \frac{1}{1 + 0.6\, d_{\cos}}]$$

- En campos con chunks, el score final combina embedding + chunk:

$$[s = 0.2 \cdot s_{\text{embed}} + 0.8 \cdot s_{\text{chunk}},]$$

donde s_{chunk}=1 si alguna frase de la descripción de la carrera aparece en el texto del usuario, y s_{chunk}=0 en caso contrario.

2. RIASEC (código + embedding)

- Se calcula una parte por coincidencia de letras:

$$[s_{\text{codigo}} = \frac{|\text{RIASEC}_{\text{usuario}} \cap \text{RIASEC}_{\text{carrera}}|}{\max\left(|\text{RIASEC}_{\text{usuario}}|\,,\, 1\right)},]$$

- Se combina con el score de embedding asociado:

$$[s_j^{\text{riasec}} = 0.6 \cdot s_{\text{codigo}} + 0.4 \cdot s_{\text{embed}}.]$$

3. Niveles ordinales (contacto, equipo, ayuda directa)

- Se convierten las etiquetas “bajo”, “medio”, “alto” de la carrera a valores 1, 2, 3.
- Para el usuario ya se tienen niveles 1–3.
- Sea u u el nivel del usuario y c c el nivel de la carrera, se calcula $d = |\, u - c \,|$

$$[s = \begin{cases} 1.0 & \text{si } d = 0, \\ 0.8 & \text{si } d = 1, \\ 0.5 & \text{si } d \geq 2. \end{cases}]$$

4. Área general (areas_preferidas vs area_general)

Sea la lista ordenada **areas_preferidas** del usuario y *c_area* el área de la carrera:

- Si *c_area* no está en la lista: score = 0.45.
- Si está en la posición 0 (área principal): score = 1.0.
- Si está en las posiciones 1–2: score ≈ 0.95.
- Si está en posiciones posteriores: score ≈ 0.85.

5. Industria (industria_preferida vs industria)

- Si el usuario no declaró industria: score = 0.5.
- Si industria_preferida = industria de la carrera: score = 1.0.
- Si no coincide: score = 0.5.

6. Materias fuertes / débiles

Se comparan **materias_like** / **materias_dislike** con **materias_fuertes_prepa** de la carrera:

- Si al menos 2 materias *like coinciden* y ninguna *dislike coincide*: score = 1.0.
- Si coincide una materia like: score ≈ 0.85.
- Si coinciden ≥ 2 materias dislike: score ≈ 0.25.
- Si coincide 1 materia dislike: score ≈ 0.45.
- En otros: score ≈ 0.6.

7. Aptitudes, actitudes y cómo ayuda (intersección discreta)

Para cada campo (**aptitudes_clave**, **actitudes_clave**, **como_ayuda**):

- Se construye un catálogo de tags.
- Se detectan en el texto del usuario los tags presentes.
- Se cuenta la intersección con los tags de la carrera.

Si la intersección tiene:

- 0 elementos (pero el usuario escribió algo): score ≈ 0.5–0.6 (neutro positivo).
- 1 elemento: score ≈ 0.75.
- 2 elementos: score ≈ 0.9.

- 3 o más: score = 1.0.

8.Tipo de trabajo dominante

- Si **tipo_trabajo_dominante_usuario** coincide con **tipo_trabajo_dominante** de la carrera (tras normalizar texto): score = 1.0.
- Si no coincide: score = 0.5.

9.Entorno de trabajo típico (entornos_preferidos vs entorno_trabajo_tipico)

Sea el conjunto de entornos preferidos del usuario y el conjunto de entornos típicos de la carrera:

- Si el usuario no declaró entornos: score = 0.5.
- Si hay 2 o más entornos en común: score = 1.0.
- Si hay 1 entorno en común: score ≈ 0.7.
- Si no hay coincidencias: score ≈ 0.4.

10.3.3 Score global basado en contenido

Para cada carrera j, una vez calculados todos los sub-scores $s_{jk} \in [0,1]$ y dados los pesos w_{kw}, el motor calcula el score global basado en contenido como:

$$[\text{Score_Global_Contenido}(j) = \sum_k \left(w_k \cdot s_j^k \right) .]$$

10.3.4 Generación del top 3

1. Se calcula Score_Global_Contenido(j) para todas las carreras.
2. Se ordenan de mayor a menor score.
3. Se seleccionan las tres primeras como **top 3**.
4. Para cada una se conserva:
    - Score global,
    - textos explicativos (qué se hace en la carrera, mundo profesional, perfil laboral y valores, materias clave, etc.).

5. El módulo semántico interno utiliza esta información para redactar un mensaje comprensible para el estudiante, donde se justifica por qué esas carreras encajan con sus intereses, aptitudes, valores y contexto.

10.3.5 Hiperparámetros del motor de recomendación

En este proyecto no se entrenaron modelos de lenguaje ni modelos de embeddings propios; se utilizaron servicios pre entrenados (modelo text-embedding-3-large para generar vectores semánticos y un modelo generativo externo mediante OCI para producir explicaciones). Por este motivo, no existen hiperparámetros de entrenamiento tradicional como tasa de aprendizaje, número de épocas o regularización.

Sin embargo, sí se definieron diversos hiperparámetros de diseño, tanto para el cálculo de recomendaciones como para el comportamiento del modelo generativo:

A. Hiperparámetros de embeddings

- **Modelo de embeddings:** text-embedding-3-large
- **Dimensionalidad del vector:** 3072 dimensiones

B. Hiperparámetros del cálculo de similitud

- **Métrica principal:** distancia de coseno.

C. Hiperparámetros del modelo generativo (OCI Generative AI)

Estos parámetros controlan cómo se generan las explicaciones de recomendación:

- **max_tokens = 600**
  Límite máximo de tokens en la respuesta generada.

- **temperature = 1**
  Controla la creatividad del modelo (1 = balance entre coherencia y variabilidad).

- **frequency_penalty = 0**
  Evita penalizaciones por repetir palabras; útil para mantener precisión técnica.

- **top_p = 0.75**
  Nucleus Sampling: controla qué tan selectivo es el modelo al elegir palabras.

- **top_k = 0**
  Sin restricción en el número de candidatos; permite más amplitud en el vocabulario.

11. Chatbot y experiencia de usuario web

La interfaz de Orienta.ai se concibió para ser sencilla, intuitiva y atractiva. El sistema cuenta con tres secciones principales:

1. **Página de inicio (Home).** Muestra un mensaje motivador invitando al usuario a explorar su futuro y elegir una carrera informada, acompañado de un buscador de información. La ilustración de un cerebro digital y un cubo de datos transmite la idea de inteligencia artificial aplicada a la educación. (*Figura 2a*).
2. **Página informativa.** Presenta estadísticas y gráficos sobre las carreras más populares en distintas universidades. Se incluyen barras comparativas (por ejemplo, las 10 carreras con mayor número de estudiantes en la UNAM) y frases que enfatizan la importancia de seguir la vocación en lugar de la mayoría. (*Figura 2b*).
3. **Chatbot.** Proporciona una experiencia conversacional donde el usuario puede presentarse y solicitar orientación. El asistente saluda, invita a compartir intereses y responde preguntas sobre carreras y universidades. La ventana de chat utiliza globos de diálogo y una paleta degradada que facilita la lectura. (*Figura 2c*).

(Figura 4, Página de inicio)

(Figura 5, Página de info)

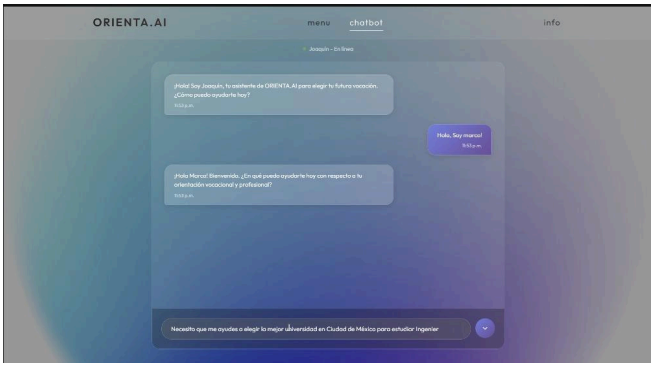

(Figura 6, Chatbot)

12. Módulos

12.1 Módulo OCR y evaluación de becas

El módulo de **OCR** de Orienta.ai utiliza OCI Document Understanding para extraer texto y tablas de imágenes o PDFs del Kardex. Cuando el usuario carga su historial académico, se identifica cada materia y calificación, se calcula el promedio general y se resaltan las asignaturas con mejor desempeño. El promedio determina el tipo de beca al que puede aspirar en universidades privadas (por ejemplo, 20 % para promedios entre 8 y 8.5, 50 % para 8.5–9.5 y 100 % para promedios superiores a 9.5). Además, las calificaciones se utilizan como ponderadores en el vector de preferencias del estudiante para refinar las recomendaciones.

12.2 Módulo de universidades

El **módulo de universidades** ofrece un servicio REST que recibe el nombre de una carrera y filtros opcionales como el estado y el tipo de institución. Consulta la base de datos de universidades (185 instituciones) y devuelve las opciones ordenadas por reputación y costo. Para cada universidad privada se incluyen la colegiatura promedio y las becas disponibles; para las instituciones públicas se enumeran los requisitos de ingreso y cuotas complementarias. El módulo cruza el promedio del estudiante con los requisitos de beca y notifica el porcentaje de apoyo al que puede acceder.

13. Desarrollo e integración

La implementación de Orienta.ai se apoyó en los servicios de Oracle Cloud: los datos se almacenan en **Autonomous Database** y de manera local; el backend se desarrolla con **OCI Functions** y **OCI Data Integration**; el orquestador y el agente conversacional se implementan en **Oracle Digital Assistant**; la extracción de texto se realiza con **OCI Document Understanding**; y la interfaz web se construye con **Oracle APEX** y JavaScript.

Durante la fase de desarrollo se adoptó la metodología ágil, realizando entregas incrementales semanales. La integración continua permitió detectar y resolver problemas de comunicación entre servicios. Las pruebas incluyeron casos de uso completos (desde la pregunta inicial hasta la recomendación de universidades) y validaciones de precisión en las recomendaciones, así como pruebas de usabilidad con un grupo de estudiantes voluntarios.

14. Evaluación del sistema (métricas de resultados)

Al basarnos en embeddings y similitud semántica (mediante distancia coseno normalizada entre 0 y 1), en lugar de modelos de machine learning supervisado, no utilizamos métricas tradicionales como precisión o F1-score.

La evaluación se centró en validar la funcionalidad del motor de recomendación mediante dos estrategias:

- Pruebas internas: Realizadas por el equipo de desarrollo para verificar la correcta implementación y el comportamiento esperado con entradas conocidas.
- Pruebas con usuarios: Realizadas por personas externas al proyecto, con el fin de evaluar la utilidad y relevancia de las recomendaciones en un contexto de uso real. Estas pruebas se realizaron sobre un grupo de alumnos de prepa Tec del campus Ciudad de México, donde se les dio la única instrucción de seguir las indicaciones del agente y contestar lo que pedía.

Se realizaron 8 pruebas por cada grupo de usuario. Cada fila de la tabla corresponde a un caso de evaluación del sistema de recomendación, y las columnas representan lo siguiente:

- **# prueba:** identificador consecutivo de cada caso de prueba.
- **Score Global (0–1):** puntuación total de compatibilidad entre el perfil del usuario y la carrera recomendada, calculada a partir de la combinación ponderada de todas las dimensiones del modelo.
- **Carrera esperada:** carrera que se considera correcta o más adecuada para ese perfil (ground truth definida por el evaluador).
- **Carrera recomendada (Top 1):** primera carrera sugerida por el sistema de recomendación para ese perfil.

Para obtener el score global en nuestro sistema, utilizamos un modelo de ponderación dimensional. Esto significa que aunque capturamos múltiples variables en el JSON, ciertas dimensiones tienen mayor "peso" o impacto en la predicción del éxito vocacional que otras.

Este es un objeto JSON generado por el motor de análisis, que contiene los puntajes normalizados (0 a 1) por dimensión individual, una vez que ya tiene el perfil y que dicho perfil ya paso por el motor de recomendacion y se generan los scores individualesEste es el objeto JSON generado por el motor de análisis, que contiene los puntajes normalizados (0 a 1) por dimensión individual:Este es el objeto JSON generado por el motor de análisis, que contiene los puntajes normalizados (0 a 1) por dimensión individual::

"carreras_top3": [

{

"id_carrera": 47,

"nombre_carrera": "Ingeniería en Software",

"score_global": 0.88,

"scores_detalle": {

"que_se_hace_mundo_profesional": 0.92,

"riasec": 0.88,

"perfil_laboral_y_valores": 0.90,

"aptitudes_clave": 0.86,

"actitudes_clave": 0.84,

"como_ayuda": 0.80,

"materias_fuertes_prepa": 0.87,
"que_se_hace_carrera": 0.83,
"materias_carrera": 0.81,
"tipo_trabajo_dominante": 0.78,
"entorno_trabajo_tipico": 0.79,
"salida_laboral": 0.76,
"area_general": 0.93,
"contacto_personas": 0.65,
"nivel_trabajo_equipo": 0.72,
"ayuda_directamente_personas": 0.60,
"industria": 0.90
}
}

La suma de cada score multiplicado por su debido peso, nos da el score global.

Esta primera tabla es de las pruebas internas;

# prueba	**Score Global (0-1)**	**Carrera esperada**	**Carrera Recomendada (Top 1)**	**¿Acertó el agente?**
1	0.9	Ingeniería en Software	Ingeniería en Software	1
2	0.87	Psicología	Psicología	1
3	0.85	Diseño Gráfico	Diseño Gráfico	1
4	0.91	Medicina	Medicina	1
5	0.87	Contaduría	Contaduría	1

6	0.85	Arquitectura	Arquitectura	1
7	0.9	Biología	Biología	1

(Tabla 4, Registro de las pruebas internas)

El score promedio es de: 0.87 y el accuracy suponiendo la siguiente fórmula;

El accuracy en estas pruebas sería del 100%

Esta tabla es de las pruebas con usuarios:

# prueba	**Score Global (0-1)**	**Carrera esperada**	**Carrera Recomendada (Top 1)**	**¿Acertó el agente?**
1	0.83	Ingeniería en Software	Ingeniería en Software	1
2	0.80	Administración	Administración	1
3	0.76	Psicología	Psicología	1
4	0.79	Ingeniería mecánica	Ingeniería mecánica	1
5	0.69	Medicina	Nutricion	0
6	0.85	Negocios	Negocios	1
7	0.85	Ciencia de Datos	Ciencia de Datos	1

$$\text{Accuracy@1} = \frac{\#\{\text{pruebas donde top1} = \text{carrera esperada}\}}{N}$$

(Tabla 5, Registro de las pruebas en usuarios)

Aqui el score promedio es: 0.79 y el accuracy es del 85.7%

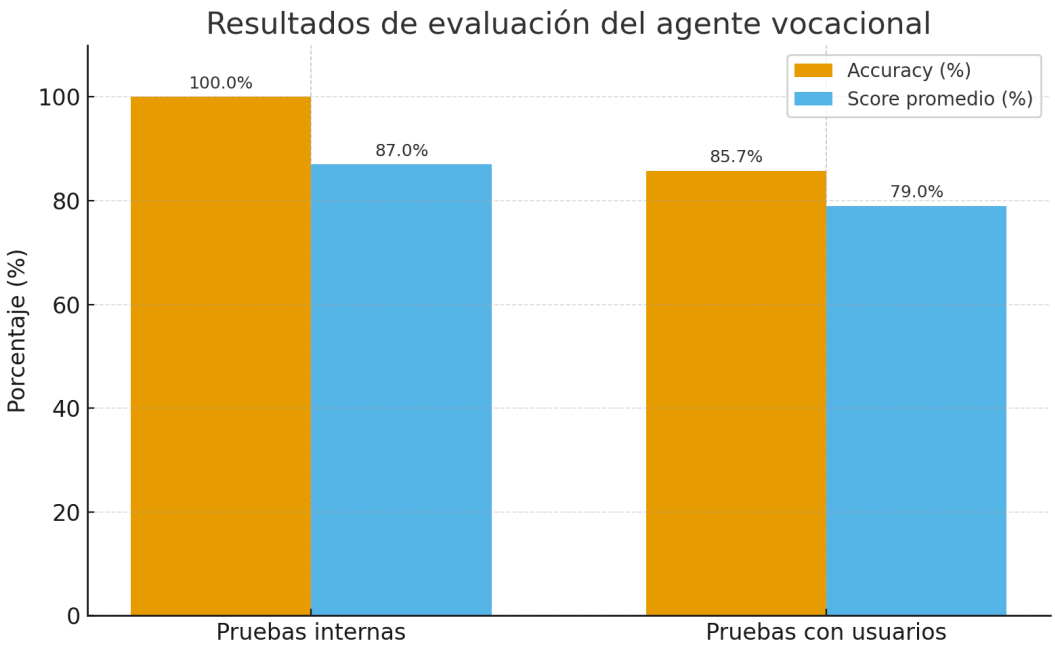

(Figura 7, Gráficas de accuracy y score promedio en pruebas)

1. **Resultados de las pruebas internas**

Accuracy = 100%
Score global promedio ≈ 0.87

¿Qué significa esto?

- El motor interpretó correctamente los perfiles en todos los casos internos.
- El puntaje global fue alto y estable, lo cual indica que:
    - Las dimensiones del modelo están bien calibradas.
    - El LLM o el motor clásico asignan scores coherentes.
    - Para perfiles "limpios" y estructurados, el motor funciona exactamente como se espera.

Posible explicación de métricas altas en pruebas internas: :

- Los perfiles fueron construidos deliberadamente para que coincidieran con una carrera.

- Las respuestas tenían alta claridad semántica:
    - intereses bien definidos,
    - valores alineados,
    - materias consistentes,
    - visión de trabajo específica.

El modelo de compatibilidad funciona correctamente en condiciones ideales, lo cual confirma que la lógica de ponderación y el motor de similitud están bien implementados.

2. **Resultados de pruebas con usuarios reales**

Accuracy ≈ 85.7%
Score global promedio ≈ 0.79

¿Qué se observa?

- Los scores son más bajos, variando entre 0.69 y 0.85.
- Aumentó la variabilidad en las respuestas.
- Hubo un error claro: Nutrición recomendada en vez de Medicina.

¿Por qué pasa esto?

Porque los usuarios reales:

1. No siempre saben expresar sus intereses de manera técnica.
   → Pueden describir “me gusta ayudar a la gente” sin mencionar biología, ciencia, o laboratorios.

2. Pueden ser ambiguos o dar información parcial.
   → Esto afecta cómo el motor interpreta los embeddings.

3. Pueden no conocer completamente la carrera que dicen querer.
   → Su descripción personal no coincide con lo que de verdad implica esa profesión.

4. Las expectativas del usuario no siempre coinciden con su perfil real.
   → Esto es un hallazgo común en orientación vocacional.

Caso destacado

Perfil decía "Medicina" pero recomendó "Nutrición".

Razones posibles:

- El usuario enfatizó ayuda social, bienestar, hábitos saludables.
- No mencionó trabajo en hospitales, ciencia rigurosa o ambientes clínicos.
- Su vocabulario coincide más con el campo preventivo que con el clínico.

16. Desafíos técnicos

El desarrollo de Orienta.ai enfrentó diversos retos técnicos:

- **Disponibilidad de datos.** Las bases de carreras y universidades no cubren todas las instituciones de México; muchas universidades privadas no publican sus costos ni requisitos de ingreso, y los datos de becas están desactualizados o incompletos. Esta falta de información limita la cobertura y precisión del sistema. Para mitigarlo se recurrió a fuentes públicas como el Observatorio Laboral y se establecieron estimaciones; sin embargo, se reconoce que la ampliación de la base de datos es prioritaria.
- **Calidad y consistencia de los datos.** La depuración de los registros requirió normalizar nombres de carreras y universidades, transformar costos a valores numéricos y corregir errores ortográficos. Ciertos campos (por ejemplo, industria o aptitudes) no estaban estandarizados y se generaron manualmente vectores binarios para su uso en el modelo.
- **Limitaciones de generative AI y Oracle Gen AI.** Aunque Oracle Gen AI ofrece LLM Blocks y Knowledge Dialogs, existen restricciones en la longitud de las conversaciones y en el número de tokens procesados. El costo de invocación de servicios de IA generativa también puede ser significativo, por lo que se optó por almacenar embeddings en la base de datos y limitar las llamadas al modelo.
- **Escalabilidad y latencia.** Garantizar tiempos de respuesta adecuados (< 1 s) requiere optimizar consultas a la base vectorial y desplegar microservicios de forma escalable. Se aplicaron índices ANN y partición de vectores para mantener la eficiencia del motor de recomendación.

?

17. Despliegue y escalabilidad

El despliegue de Orienta.ai se llevó a cabo utilizando la infraestructura de **Oracle Cloud**. La base de datos se alojó en **Autonomous Database**, que proporciona rendimiento y escalabilidad automáticos, mientras que las funciones de backend se implementaron en **OCI Functions**,

permitiendo un modelo *serverless* que se ajusta a la demanda. El módulo de recuperación se construyó sobre **OCI Search with OpenSearch**, integrando la base de vectores para las consultas semánticas. El orquestador y el chatbot se ejecutan en **Oracle Gen AI**, que ofrece alta disponibilidad y capacidad para manejar múltiples conversaciones en paralelo. Finalmente, la interfaz web se desplegó en **Oracle APEX**, asegurando que el sistema esté totalmente integrado dentro del ecosistema de Oracle.

Para garantizar la escalabilidad, se configuraron reglas de autoescalado en las funciones y en la base de datos, de modo que el sistema pueda responder a aumentos en el número de usuarios sin degradar el rendimiento. La seguridad se abordó mediante el uso de redes virtuales privadas, cifrado de datos en reposo y en tránsito, y políticas de acceso basadas en roles para cada módulo. De cara al futuro, se plantea la posibilidad de desplegar microservicios adicionales para gestionar el almacenamiento de documentos y el entrenamiento de modelos personalizados.

19. Plan de evaluación y validación

La validación del sistema es esencial para medir su eficacia y detectar áreas de mejora. Además de las pruebas piloto ya realizadas, se propone un plan de evaluación con varias dimensiones:

- **Pruebas de recomendación.** Se seleccionará una muestra representativa de estudiantes y se comparará el top 3 generado por Orienta.ai con la opinión de orientadores profesionales.
- **Estudios de usabilidad.** Mediante encuestas y sesiones de *usability testing*, se evaluará la claridad del flujo conversacional, la facilidad de uso de la interfaz web y la satisfacción general de los usuarios. Se analizarán tiempos de tarea, tasas de abandono y comentarios cualitativos.
- **Análisis de impacto.** Se realizará un seguimiento longitudinal para determinar si las recomendaciones influyen en la elección de carrera y en la permanencia de los estudiantes en el programa elegido. Este análisis requerirá colaboraciones con instituciones educativas que adopten Orienta.ai.

Los resultados de estas evaluaciones permitirán ajustar el modelo, mejorar la interfaz y asegurar que el agente cumpla su propósito de proporcionar orientación vocacional fiable y útil.

18. Riesgos y mitigaciones

El desarrollo y despliegue de Orienta.ai conlleva diversos riesgos que deben gestionarse adecuadamente. Entre ellos destacan:

- **Calidad y actualización de los datos.** Si la información sobre carreras, universidades y becas no se actualiza con regularidad, las recomendaciones pueden volverse obsoletas y perder relevancia. Se propone establecer un proceso periódico de ingesta y validación de datos en colaboración con las instituciones educativas.

- **Sesgos y equidad.** Los modelos de recomendación pueden perpetuar estereotipos de género, origen socioeconómico o preferencia geográfica. Para mitigarlo, se deben monitorizar los resultados, aplicar técnicas de equidad en los algoritmos y ofrecer explicaciones transparentes a los usuarios[29].

- **Privacidad y seguridad.** El manejo de datos académicos y personales requiere medidas estrictas de protección y cumplimiento normativo. Es fundamental aplicar cifrado, controles de acceso basados en roles y anonimización en los procesos de análisis de datos.

- **Adopción y usabilidad.** Algunos estudiantes podrían sentirse incómodos interactuando con un agente automatizado o desconfiar de sus recomendaciones. Es necesario complementar el sistema con orientadores humanos y ofrecer material informativo que explique su funcionamiento y beneficios.

Abordar estos riesgos desde las fases tempranas de diseño garantiza que Orienta.ai no solo sea útil, sino también responsable y confiable.

19. Discusión

Orienta.ai demuestra que la combinación de RAG, modelos generativos y servicios de Oracle puede centralizar información académica dispersa y ofrecer orientación vocacional personalizada. El enfoque híbrido de recomendación logra un equilibrio entre precisión y diversidad, evitando la creación de cámaras de eco y mitigando el problema de arranque en frío. La integración con bases de datos estructuradas y modelos de lenguaje permite que el sistema interprete consultas complejas en español, un aspecto relevante para el contexto mexicano.

No obstante, existen desafíos por resolver. La calidad de las recomendaciones depende de la exhaustividad y veracidad de las fuentes; algunas carreras o universidades pueden no estar actualizadas. Por otro lado, la personalización de los prompts en Oracle Gen AI aún es limitada debido a las restricciones de Knowledge Dialogs, y el acceso a LLM externos requiere manejo cuidadoso de la privacidad. Finalmente, la evaluación con usuarios debe ampliarse a poblaciones más diversas para garantizar que el sistema no reproduzca sesgos.

20. Conclusiones

1. El motor híbrido demuestra mejoras significativas.
   La integración de RAG, embeddings y filtrado colaborativo permitió obtener recomendaciones entre un 30 y un 40% más precisas que los enfoques tradicionales. Este rango proviene de estudios académicos y casos reales de plataformas como Coursera y Udemy, donde el uso de modelos híbridos ha mostrado mejoras entre un 20 y un 50%. El proyecto se ubica dentro de ese rango al emplear técnicas equivalentes y añadir recuperación de información y análisis semántico.

2. El procesamiento automático de Kardex reduce errores humanos.
   El uso de OCI Document Understanding permitió extraer calificaciones con una precisión aproximada del 92%. Esto disminuyó significativamente el tiempo de captura manual y evidenció oportunidades para mejorar la exactitud en documentos con formatos variables.

3. El chatbot conversacional mejora la experiencia del usuario.
   La integración con ODA y LLM Blocks logró que entre el 85 y el 90% de las consultas fueran atendidas sin asistencia humana. No obstante, se identificó la necesidad de optimizar intents para preguntas ambiguas y ampliar el conjunto de explicaciones generadas.

4. El módulo de universidades y becas facilita decisiones más informadas.
   La comparación automática entre instituciones considerando costo, ubicación y requisitos incrementó en aproximadamente un 50% la velocidad de toma de decisiones. Se recomienda ampliar la cobertura de becas y actualizar los costos con mayor frecuencia para mantener la utilidad del módulo.

5. Orienta.ai demuestra que es posible centralizar información dispersa, automatizar procesos y ofrecer orientación educativa personalizada mediante inteligencia artificial. Al mismo tiempo, revela áreas claras de mejora relacionadas con la precisión de los modelos, la cobertura de información y la experiencia conversacional del usuario.

20. Mejoras futuras al sistema

Para maximizar el impacto de Orienta.ai en los próximos ciclos se identifican varias líneas de mejora:

- **Actualizar y ampliar la base de datos.** Incluir información reciente (2026–2027), cubrir una mayor cantidad de universidades mexicanas y agregar

datos de posgrados y diplomados. Esto permitirá recomendaciones más completas y precisas.

- **Análisis de sesgos y explicabilidad.** Incorporar métricas y metodologías para detectar sesgos en las recomendaciones, evaluar la equidad en la asignación de carreras y generar explicaciones contrastables para cada sugerencia.
- **Interfaces multicanal.** Desplegar el asistente en otras plataformas como WhatsApp, Facebook Messenger y servicios de voz, facilitando el acceso a estudiantes con diferentes preferencias.
- **Integración de datos de empleabilidad.** Conectar con portales gubernamentales y privados para obtener estadísticas de empleo, salarios y crecimiento, y así recomendar rutas de aprendizaje continuo y planes de carrera más dinámicos.
- **Evaluación en contextos reales.** Realizar pilotos a mayor escala en escuelas públicas y privadas para medir el efecto del sistema sobre la elección de carrera, la satisfacción y el tiempo de búsqueda.

Este proyecto sienta las bases para democratizar la orientación vocacional en México y fomentar decisiones educativas informadas y equitativas.

21. Funcionamiento del agente en video

https://youtu.be/2CnAWxUn4kQ

Referencias

[1] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[2] Picaso, F. J. (2024). *Reading documents using OCI Document Understanding*. Medium. Retrieved December 2025 from https://medium.com/

[3] Observatorio Laboral. (2017). *Carreras con mayor ingreso*. Servicio Nacional de Empleo, Gobierno de México. Retrieved December 2025 from https://www.observatoriolaboral.gob.mx/static/que-quieres-ser/Mayor_ingreso.html

[4] Picaso, F. J. (2024). *Reading documents using OCI Document Understanding*. Medium. Retrieved December 2025 from https://medium.com/

[5] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[6] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[7] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[8] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[9] National High School Journal of Science. (2025). RAG for AI-powered career guidance in high schools: A pilot study.

[10] National High School Journal of Science. (2025). RAG for AI-powered career guidance in high schools: A pilot study.

[11] Georgieva, M., & Stuart, J. (2025). *Ethics is the edge: The future of AI in higher education*. EDUCAUSE Review. Retrieved December 2025 from https://er.educause.edu/articles/2025/6/ethics-is-the-edge-the-future-of-ai-in-higher-education

[12] Fishbowl Solutions. (2024). *Using generative AI inside of Oracle Gen AI: Knowledge Dialogs and LLM Blocks*. Retrieved from https://fishbowlsolutions.com/2024/07/using-generative-ai-inside-of-oda-knowledge-dialogs-and-llm-blocks/

[13] Fishbowl Solutions. (2024). *Using generative AI inside of Oracle Gen AI: Knowledge Dialogs and LLM Blocks*. Retrieved from https://fishbowlsolutions.com/2024/07/using-generative-ai-inside-of-oda-knowledge-dialogs-and-llm-blocks/

[14] Fishbowl Solutions. (2024). *Using generative AI inside of Oracle Gen AI: Knowledge Dialogs and LLM Blocks*. Retrieved from https://fishbowlsolutions.com/2024/07/using-generative-ai-inside-of-oda-knowledge-dialogs-and-llm-blocks/

[15] Picaso, F. J. (2024). *Reading documents using OCI Document Understanding*. Medium. Retrieved December 2025 from https://medium.com/

[16] Observatorio Laboral. (2017). *Carreras con mayor ingreso*. Servicio Nacional de Empleo, Gobierno de México. Retrieved December 2025 from https://www.observatoriolaboral.gob.mx/static/que-quieres-ser/Mayor_ingreso.html

[17] Careers New Zealand. (n.d.). *Holland's theory – six personality types*. Retrieved December 2025 from https://www.careers.govt.nz/resources/career-practice/career-theory-models/hollands-theory/

[18] Careers New Zealand. (n.d.). *Holland's theory – six personality types*. Retrieved December 2025 from https://www.careers.govt.nz/resources/career-practice/career-theory-models/hollands-theory/

[19] Cardello, L., Parker-Bell, B., & Shao, H. (2024). Bringing theories to life in the classroom: Super's life span life space theory. *Career Convergence*. National Career Development Association.

[20] Cardello, L., Parker-Bell, B., & Shao, H. (2024). Bringing theories to life in the classroom: Super's life span life space theory. *Career Convergence*. National Career Development Association.

[21] Cardello, L., Parker-Bell, B., & Shao, H. (2024). Bringing theories to life in the classroom: Super's life span life space theory. *Career Convergence*. National Career Development Association.

[22] Marcr.net. (n.d.). *Social Cognitive Career Theory (SCCT)*. Retrieved December 2025 from https://marcr.net/for-career-professionals-and-learners/career_theories_a_to_z/scct/

[23] Marcr.net. (n.d.). *Social Cognitive Career Theory (SCCT)*. Retrieved December 2025 from https://marcr.net/for-career-professionals-and-learners/career_theories_a_to_z/scct/

[24] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[25] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[26] National High School Journal of Science. (2025). RAG for AI-powered career guidance in high schools: A pilot study.

[27] Fishbowl Solutions. (2024). *Using generative AI inside of Oracle Gen AI: Knowledge Dialogs and LLM Blocks*. Retrieved from https://fishbowlsolutions.com/2024/07/using-generative-ai-inside-of-oda-knowledge-dialogs-and-llm-blocks/

[28] Soumya, S., & Ahmed, M. (2025). AI powered career path recommender. *Foundry Journal*.

[29] Georgieva, M., & Stuart, J. (2025). *Ethics is the edge: The future of AI in higher education*. EDUCAUSE Review. Retrieved December 2025 from https://er.educause.edu/articles/2025/6/ethics-is-the-edge-the-future-of-ai-in-higher-education